DealLens ML Finansal Risk Karşılaştırması

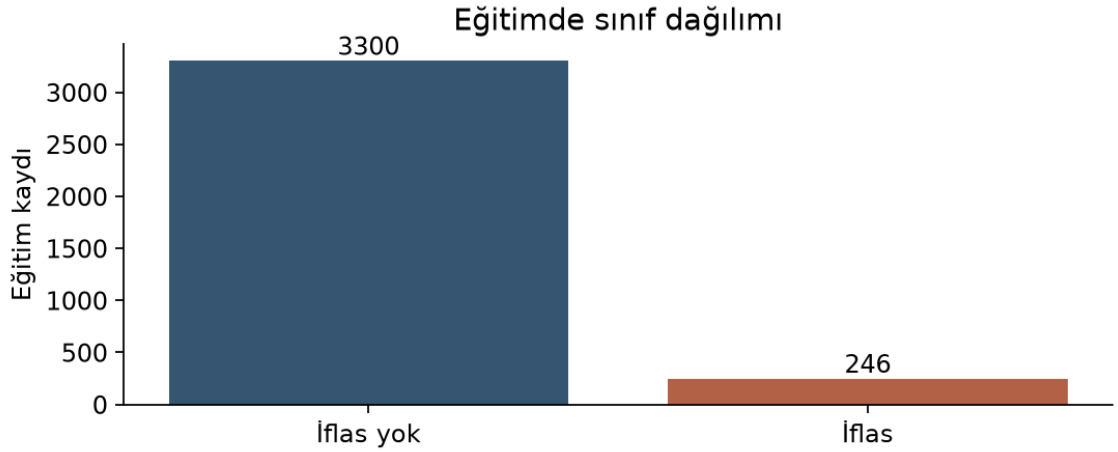
Mustafa Yüksel · Software Persona ikinci proje · 9 Ekim 2026

Bu çalışma, 64 finansal oranla iflas etiketini ayırt eden üç yöntemi karşılaştırıyor. Eğitim içindeki ölçüme göre seçilen CatBoost, testte 82 pozitif kaydın 56'sını yakaladı; F1 %71,79 oldu. Daha düşük alarm eşiği yalnız bir ek pozitif yakalarken beş ek yanlış alarma yol açtı. Sonuçlar tarihsel eğitim verisine aittir.

Problem ve veri kapsamı

Soru, hangi modelin riskli kayıtları daha iyi sıraladığı ve kaçırılan risk ile yanlış alarm arasındaki dengenin nasıl değiştiğidir. Girdi Attr1–Attr64 finansal oranları, çıktı bir yıl sonraki iflas etiketidir. Hedef şirket satın alma uygunluğu değildir.

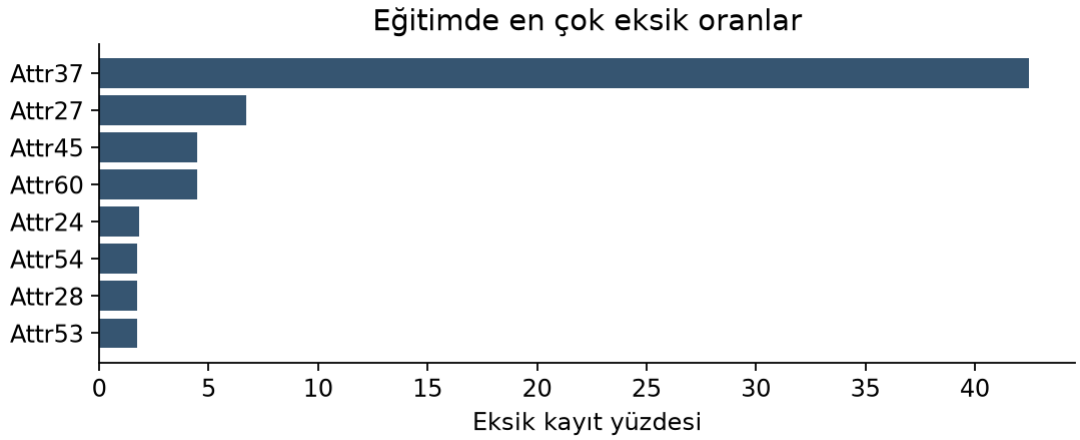
Kaynak UCI Polish Companies Bankruptcy veri setinin 5year.arff dosyasıdır: 5.910 finansal tablo, 5.500 negatif ve 410 pozitif etiket. Kaynak Polonya'nın tarihsel verilerini içerir. record_id şirket kimliği değil kaynak satır numarasıdır. 60 ek satır aynı 64 girdiye sahiptir; satırlar silinmeden aynı bölüme gruplanmıştır.



Şekil 1 Eğitim bölümünde 246 pozitif ve 3.300 negatif kayıt vardır. Pozitif oranı %6,94 olduğu için accuracy tek başına yeterli değildir.

Tüm kayıtları negatif söyleyen referans testte %93,06 doğruluk verir, fakat 82 pozitif kaydın hiçbirini yakalamaz. Bu nedenle model seçimini eğitim CV average precision ile, karar eşiğini ayrı doğrulama bölümünde F1 ile yaptım.

Veri keşfi ve ön işleme



Şekil 2 En çok eksik oranlar yalnız eğitim bölümünden hesaplandı. Attr37 ve Attr27 gibi sütunlardaki eksiklik, dış veriye taşınabilirlik açısından ayrıca incelenmelidir.

Eksik oranlar her eğitim katının medyanıyla doldurulduu. Ana modellerde eğitimde öğrenilen eksik göstergeleri eklendi. Kaynak tanımlarına göre para birimi ve oran ölçekleri farklı olabilir; yüzdeye otomatik dönüşüm yapılmadı. Sonsuz, sayısal olmayan ve bütün oranları eksik kayıtlar tahmin girişinde reddedilir.



Şekil 3 Faaliyet kârı / satışlar oranında iki sınıfın dağılımı örtüşür. Tek oranla kesin karar verilemez. Grafikteki sınırlandırma yalnız okunurluk içindir.

Lojistik regresyon ve MLP için her eğitim katında öğrenilen %1–%99 yüzdelik sınırlarıyla uç değerler sınırlanıp StandardScaler uygulandı. Bu yöntem satır silmeden büyük oranların ölçek etkisini azaltır; gerçek uç değerlerin bilgi kaybı bir sınırlılıktır. CatBoost için ek ölçekleme ve uç değer sınırlaması uygulanmadı. Hedef, kaynak kimliği ve ayrım sütunları hiçbir modelin girdisine katılmadı.

Modeller ve eğitim planı

Yöntem	Gerekçe ve önemli ayarlar
Lojistik regresyon	64 oran ve eksik göstergeleri; doğrusal referans; C=1, balanced sınıf ağırlığı, max_iter=3000
CatBoost	64 oran ve eksik göstergeleri; 300 ağaç, derinlik 5, öğrenme oranı 0,035, L2=3
Küçük MLP	32 ve 16 ReLU gizli nöron; sigmoid çıktı; log loss; Adam; L2=0,01; batch=128; lr=0,001; en fazla 600 epoch
Dummy	Çoğunluk sınıfı referansı; seçim yarışmasına alınmaz
Attr27 incelemesi	Attr27 ve ona ait eksiklik bilgisini çıkaran CatBoost; tanısal karşılaştırma, seçim adayı değil

MLP sınıf ağırlığı kullanmadı. Otomatik iç doğrulama, aynı girdili grupları ayırabileceğinden kapalıdır. Durdurma eğitim loss değişimine dayanır; bu deneyde 243 epoch çalıştı. Eğitim/CV süreçlerinde yakınsama uyarısı kaydedilmedi. Sinir ağı kullanımı daha yüksek başarı garantisi değildir.

Sabit plan 3.546 eğitim, 1.182 doğrulama ve 1.182 test kaydı içerir; pozitif sayıları 246, 82 ve 82’dir. Aynı 64 girdili kayıtlar bölümler ve eğitim CV katları arasında ayrılmaz. Plan CSV içindeki partition, partition_order ve cv_fold sütunlarından okunur; farklı kütüphane sürümleriyle yeniden rastgele ayrım yapılmaz.

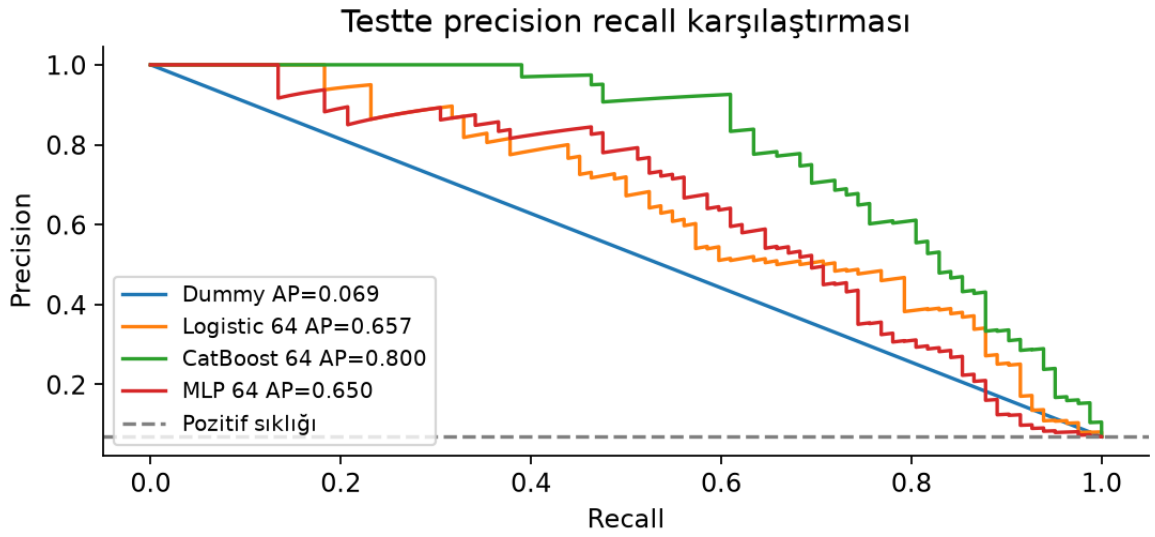
Eğitim içinde üç sabit grup CV katı kullanıldı. Her katın ön işlemesi o katın eğitim verisinde öğrenildi. Ana üç model arasında ortalama average precision en yüksek olan seçildi. Ardından her modelin F1 eşiği ayrı doğrulamada belirlendi. Seçim ve eşikler test tahminlerinden önce selection_before_test.json içine kaydedildi; daha sonra bütün veride yeniden eğitim yapılmadı.

Model	CV ortalama AP	Katlar arası std
Logistic 64	0.6164	0.0448
CatBoost 64	0.7702	0.0309
MLP 64	0.6551	0.0196

CatBoost bu ölçüme göre seçildi. CV değerleri seçim içindir; tarafsız nihai performans diye sunulmaz. Bu veri Python projesinde incelendiği için model ailesi seçiminin geçmiş bilgiden etkilendiği de açıklanmalıdır.

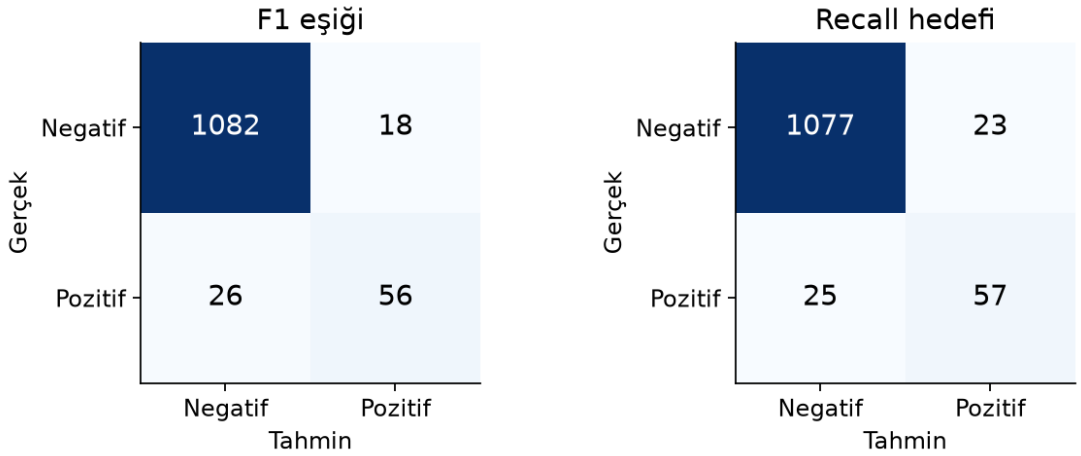
Test sonuçları ve alarm eşiği

Model	Accuracy	Precision	Recall	F1	AP
Dummy	%93,06	%0,00	%0,00	%0,00	%6,94
Logistic 64	%95,09	%70,69	%50,00	%58,57	%65,72
CatBoost 64	%96,28	%75,68	%68,29	%71,79	%80,00
MLP 64	%95,09	%66,67	%58,54	%62,34	%64,97



Şekil 4 Precision recall eğrisi riskli kayıtların sıralanmasını gösterir. AP basamak ağırlıklı average precision ölçümüdür; trapez PR alanıyla aynı ölçü değildir.

CatBoost ROC AUC 0.9564, AP 0.8000 üretti. Lojistik model doğrusal referans, MLP ise doğrusal olmayan alternatif sunar. Bu koşullarda MLP'nin F1'i %62,34 oldu; CatBoost'u geçmedi. Test sonucuna bakarak seçilen model değiştirilmedi.



Şekil 5 Sol F1 eşiği, sağ doğrulamada en az %80 recall hedefleyen eşiktir. Testte hedef recall düzeyine ulaşılmadı.

F1 eşiği 0.3345: 56 doğru alarm, 26 kaçan pozitif ve 18 yanlış alarm. İkinci eşik 0.2490: 57 doğru alarm, 25 kaçan pozitif ve 23 yanlış alarm; test recall %69,51. Doğrulamadaki hedefin testte garanti olmaması, ayrı testin değerini gösterir. Maliyetler bilinmediğinden ikinci eşiği ticari öneri olarak sunmuyorum.

Hata analizi ve sonuç

CatBoost AP eğitimde 0.9654, doğrulamada 0.8713, testte 0.8000. Eğitimle diğer bölümler arasındaki fark, eğitim başarısının yeni kayıtlardaki başarı yerine geçmediğini gösterir. Hata tablosunda yanlış alarm ve kaçan pozitifler kaynak satır numarası, oranlar, skor ve eksik oran sayısıyla listelendi. Satır numarasından gerçek şirket kimliği çıkarılamaz.

Attr27 çıkarıldığında test AP 0.6816, F1 %61,44 oldu. Bu düşüş, ilgili oran ve eksiklik bilgisinin birlikte kaldırılmasına duyarlılığı gösterir. Özelliğin doğrudan hedef sızıntısı olduğunu veya nedensel açıklama sağladığını kanıtlamaz. Önceden belirlenmiş bu inceleme model seçimine katılmadı.

Ölçüm	Grup bootstrap yüzde 95 aralığı
precision	%65,00 – %85,51
recall	%57,13 – %78,48
f1	%63,22 – %79,41
average_precision	%71,78 – %87,14

600 tekrar içeren bootstrap aynı girdili test gruplarını birlikte yeniden örnekledi. Aralıklar bu eğitilmiş model ve mevcut tarihsel test setine koşulludur; eğitim belirsizliğini, ülke farkını veya zaman değişimini kapsamaz. Özellikle 82 pozitif test kaydı recall tahmininin belirsizliğini artırır.

Sınırlar ve geliştirme

Çalışmanın güçlü yanı aynı kayıtlar, eğitim içinde ön işleme, testten önce kayıtlı seçim ve açıklanabilir hata karşılaştırmasıdır. Veri geçmiş deneylerde incelendi; yeni bağımsız dış test değildir. Şirket kimliği ve takvim ayrımı yoktur. Skorlar kalibre edilmemiştir; güncel bir Türkiye şirketinin iflas yüzdesi veya yatırım kararı olarak kullanılamaz.

Sonraki çalışma için farklı tarihten şirket kimlikli dış veri, tahmin anında oranların bulunabilirliği ve gerçek hata maliyetleri gerekir. Şirket ve zaman düzeyinde değerlendirmeden sonra ayrı veride kalibrasyon denenebilir. MLP sınıf ağırlığı ve ayarları yalnız eğitim verisi içinde araştırılmalıdır. Bu teslimde ayrı ML karşılaştırması, eşik analizi ve sınırlılıkların dürüst açıklaması tamamlanmıştır.

Kod ve kaynaklar

Colab: https://colab.research.google.com/drive/1OD_stN8UF6IF4ouJEdrpVN6mKDKFMuGi

Veri: Tomczak S. (2016), Polish Companies Bankruptcy, DOI 10.24432/C5F600, CC BY 4.0. https://archive.ics.uci.edu/dataset/365/polish+companies+bankruptcy+data

Yöntem: scikit-learn supervised neural networks ve model evaluation belgeleri. https://scikit-learn.org/stable/modules/neural_networks_supervised.html ve /stable/modules/model_evaluation.html. Erişim 09.10.2026. AI destekli geliştirme kullanıldı; kişisel kavrayış ve resmi form teslimi ayrı teyit gerektirir.